

Clasificación de Voces Patológicas y Saludables

Procesamiento de Señales de Audio y Habla
PSAHA

Noelia Falczuk

Julio 2025

1. Introducción

La motivación es introducirme en el mundo del diagnóstico médico usando técnicas de ML y poner en práctica los conocimientos teóricos adquiridos durante el curso. En este trabajo, se desarrolló un sistema de clasificación binaria para distinguir entre voces saludables y voces patológicas, utilizando grabaciones de audio y técnicas de aprendizaje automático. Además, se comparan dos datasets cuyos audios tienen 'origen' distinto para ver si es posible aprender características que van más allá de la procedencia del sonido.

2. Dataset

Se trabajó con la **Saarbrücken Voice Database (SVD)**. Contiene grabaciones de sujetos tanto saludables como con patologías vocales. Además, se usaron datos del dataset VOICED.

Veremos que los datos más adecuados para la clasificación son los de SVD y que es limitada la transferencia de modelos entrenados con un dataset a otros sin tratamiento de dominios.




Figura 1: Distribución de clases.

3. Extracción de Características

Utilizando `librosa`, `parselmouth` y otras librerías, se calcularon los siguientes atributos para cada señal de voz:




Figura 2: Visualización PCA en 2D: diferenciación por clase y por origen del dataset.

- MFCCs (1 al 13)
- Spectral Centroid
- Spectral Flatness
- ZCR
- HNR

La clase positiva se considera como la clase “1” (no saludable), que es la condición que se busca detectar, mientras que la clase “0” representa la clase negativa (saludable). Ambos datasets presentan un desbalance entre clases. Para afrontar este problema se utilizaron técnicas de resampling y métricas robustas al desbalance como TPR, FPR, F1, G-Mean y MCC. En el dataset SVD, la clase mayoritaria es la saludable (0), y en VOICED la clase mayoritaria es la no saludable (1).

4. Análisis de Características

Para identificar cuáles atributos acústicos distinguen entre voces saludables y patológicas, se aplicó el **test de rangos de Wilcoxon (ranksum)** para cada variable del dataset. Este test no paramétrico permite comparar dos muestras independientes (clase 0 y clase 1), sin asumir normalidad. Para cada variable, evalúa si existe una diferencia significativa entre dos clases mediante el p-valor obtenido.

Los seis atributos más relevantes fueron para el dataset SVD:

- MFCC_1_std
- spectral_flatness_mean

- hnr spectral_centroid_std
- MFCC_10_mean

Y para el dataset VOICED:

- MFCC_2_mean
- spectral_flatness_mean
- zcr_mean
- hnr_librosa
- spectral_centroid_mean
- MFCC_1_mean

En la Figura 3 se muestran los boxplots de los cinco atributos más relevantes para el dataset SVD, lo sugiere que el modelo debería lograr capturar las diferencias entre ambas clases para clasificar correctamente. En la Figura 4 se muestran los boxplots de los cinco atributos más relevantes para el dataset VOICED. A diferencia de lo que sucedía, parecería que las distribuciones de los datos son similares por lo que no esperaríamos que modelos simples puedan separarlos fácilmente.




Figura 3: Visualización de atributos relevantes para el dataset SVD




Figura 4: Visualización de atributos relevantes para el dataset VOICED

5. Modelado

Se implementaron y compararon diferentes enfoques:

5.1. Modelos clásicos

Usando las features tabulares:

- SVM
- KNN
- Árboles de decisión
- Random Forest
- Regresión logística

Se utilizó RandomizedSearchCV para ajuste de hiperparámetros y validación cruzada.

5.2. Redes neuronales

- Perceptrón multicapa sobre las features extraídas.

6. Evaluación

Las métricas utilizadas son:

Métrica	Descripción
Sensibilidad (TPR)	% de voces patológicas correctamente detectadas
Especificidad (TNR)	% de voces saludables correctamente clasificadas
F1 Macro	evalúa el rendimiento en todas las clases por igual.
G-Mean	Media geométrica entre TPR y TNR
UAR	Unweighted Average Recall
MCC	Coefficiente de correlación de Matthews

Modelo	TPR	TNR	F1 macro	G-Mean	UAR	BM	MCC
SVM	0.3333	0.5000	0.3753	0.4082	0.4167	-0.1667	-0.1550
KNN	0.4667	0.8333	0.5675	0.6236	0.6500	0.3000	0.2791
Árbol Decisión (DT)	0.4000	0.5000	0.4167	0.4472	0.4500	-0.1000	-0.0913
Random Forest (RF)	0.3667	0.7500	0.4750	0.5244	0.5583	0.1167	0.1118
AdaBoost	0.4333	1.0000	0.5950	0.6583	0.7167	0.4333	0.4235
Naive Bayes (NB)	0.4333	0.7500	0.5195	0.5701	0.5917	0.1833	0.1705

Cuadro 1: Comparación de métricas por modelo para dataset VOICED

Modelo	TPR	TNR	F1 macro	G-Mean	UAR	BM	MCC
SVM	0.5701	0.9554	0.7802	0.7380	0.7628	0.5255	0.5632
KNN	0.7196	0.9064	0.7763	0.8076	0.8130	0.6260	0.5612
Árbol Decisión (DT)	0.4019	0.9302	0.6776	0.6114	0.6660	0.3320	0.3575
Random Forest (RF)	0.4860	0.9703	0.7633	0.6867	0.7281	0.4563	0.5423
AdaBoost	0.7477	0.8306	0.7098	0.7880	0.7891	0.5783	0.4602
Naive Bayes (NB)	0.6168	0.8425	0.6792	0.7209	0.7297	0.4593	0.3812

Cuadro 2: Comparación de métricas por modelo para dataset SVD

Experimento	Modelo	TPR	TNR	F1 macro	GM	UAR	BM	MCC
VOICED $\rightarrow$ SVD	SVM	1.0000	0.0000	0.1202	0.0000	0.5000	0.0000	0.0000
	KNN	1.0000	0.0053	0.1260	0.0731	0.5027	0.0053	0.0271
	DT	0.7317	0.2685	0.3200	0.4432	0.5001	0.0002	0.0002
	RF	0.9381	0.0686	0.1836	0.2537	0.5033	0.0067	0.0092
	AdaBoost	0.8386	0.1636	0.2554	0.3705	0.5011	0.0023	0.0021
	NB	1.0000	0.0000	0.1202	0.0000	0.5000	0.0000	0.0000
SVD $\rightarrow$ VOICED	SVM	0.0000	1.0000	0.2151	0.0000	0.5000	0.0000	0.0000
	KNN	0.0066	0.9825	0.2195	0.0807	0.4945	-0.0109	-0.0499
	DT	0.0662	0.9298	0.2718	0.2481	0.4980	-0.0040	-0.0070
	RF	0.9735	0.0351	0.4482	0.1848	0.5043	0.0086	0.0229
	AdaBoost	0.9536	0.0526	0.4574	0.2240	0.5031	0.0063	0.0131
	NB	0.1854	0.7719	0.3423	0.3783	0.4787	-0.0426	-0.0478

Cuadro 3: Resultados de métricas para modelos entrenados en VOICED y testeados en SVD, y viceversa

Experimento	Modelo	TPR	TNR	F1 macro	GM	UAR	BM	MCC
VOICED $\rightarrow$ SVD	SVM	0.0000	1.0000	0.3333	0.0000	0.5000	0.0000	0.0000
	KNN	0.8907	0.3769	0.6079	0.5794	0.6338	0.2676	0.3119
	DT	0.1497	0.8420	0.4272	0.3550	0.4958	-0.0083	-0.0115
	RF	0.3273	0.7048	0.4982	0.4803	0.5160	0.0321	0.0346
	AdaBoost	0.4339	0.5806	0.5046	0.5019	0.5073	0.0146	0.0147
	NB	0.9935	0.0015	0.3335	0.0384	0.4975	-0.0050	-0.0399
SVD $\rightarrow$ VOICED	SVM	0.0000	1.0000	0.3333	0.0000	0.5000	0.0000	0.0000
	KNN	0.2807	0.8246	0.5169	0.4811	0.5526	0.1053	0.1254
	DT	0.2281	0.7544	0.4534	0.4148	0.4912	-0.0175	-0.0206
	RF	0.0000	1.0000	0.3333	0.0000	0.5000	0.0000	0.0000
	AdaBoost	0.8772	0.1053	0.4022	0.3039	0.4912	-0.0175	-0.0276
	NB	0.1754	0.7193	0.4032	0.3552	0.4474	-0.1053	-0.1254

Cuadro 4: Resultados de modelos entrenados con VOICED y testeados en SVD, y viceversa luego de balancear

Se observa que a pesar de que aunque algunos modelos no sean buenos, salvo para knn o rf para SVD, cuando se entrena y evalúa los modelos en el mismo dataset, las métricas son más constantes y se logran aprender características de las clases. Sin embargo, estas no parecen ser generalizables a datos de otras características (experimento SVD $\rightarrow$ VOICED y VOICED $\rightarrow$ SVD).

El dataset VOICED parecería no ser bueno para distinguir las clases pues las métricas son bajas en todos los casos.

Al analizar los resultados de los modelos entrenados en VOICED y testeados en SVD se observa que, luego del balanceo, el TPR empeora considerablemente, mientras que el TNR mejora de forma notable. Esto puede explicarse porque el balanceo implica un resamplio de la clase minoritaria, que en este caso es la clase negativa (saludable). Al hacer oversampling favorece que el modelo prediga más correctamente esa clase, incrementando TNR, pero empeorando la detección de la clase positiva, disminuyendo el TPR.

Por otro lado, en el experimento SVD $\rightarrow$ VOICED, el balanceo mejora y empeora algunas las métricas en comparación con el modelo sin balanceo. Esto puede estar asociado a la cantidad y calidad de datos disponibles en cada dataset: el dataset VOICED es mayor, mientras que el SVD es más pequeño, lo que dificulta el aprendizaje generalizable.

Evaluación de modelo de Redes Neuronales

Con el objetivo de evaluar el desempeño de las redes neuronales recurrentes (RNN) en la tarea de clasificación, se comparó el desempeño de entrenar sobre un dataset y testear en otro como previamente se mostró. Basandose en la hipótesis de que las redes neuronales son capaces de trabajar y aprender relaciones usando varios atributos, se trabajó con todas las columnas / atributos extraídos.

Resultados en entrenamiento y testeo cruzados

Métrica	SVD $\rightarrow$ SVD	VOICED $\rightarrow$ VOICED	VOICED $\rightarrow$ SVD	SVD $\rightarrow$ VOICED
TPR	0.7009	0.7333	0.3640	0.3046
TNR	0.9584	0.5000	0.9017	0.6842
F1 macro	0.8349	0.6101	0.6337	0.4080
GM	0.8196	0.6055	0.5729	0.4565
UAR	0.8297	0.6167	0.6328	0.4944
BM	0.6593	0.2333	0.2657	-0.0112
MCC	0.6700	0.2236	0.2674	-0.0108

Cuadro 5: Resumen de métricas globales




Figura 5: Visualización de métricas o resultados para cada configuración de entrenamiento y evaluación.

Los resultados muestran que el modelo SVD → SVD presenta un desempeño relativamente bueno. Sin embargo, en VOICED → VOICED, aunque la sensibilidad es mejor, la especificidad (TNR) disminuye considerablemente a 0.50, indicando dificultades para

detectar correctamente la clase negativa, lo cual tiene sentido debido a que se trata de la clase minoritaria. Esto se observa también en las matrices de confusión y en los gráficos de probabilidades con los que detecta a cada clase.

Por otro lado, al evaluar modelos entrenados en un dataset y testeados en otro, el rendimiento decae. En ambos casos parecería que el modelo tiende a predecir la clase negativa.

Habiendo visto que las distribuciones de datos entre VOICED y SVD son diferentes los modelos no pueden transferir lo aprendido a otro dataset. En consecuencia, la generalización no es posible aunque los modelos funcionan bien en su dataset.

7. Conclusiones

Los resultados muestran que es posible alcanzar buenos niveles de sensibilidad y especificidad cuando el entrenamiento y la evaluación se realizan dentro del mismo dataset. Además, se observa que se cumplen las conjeturas iniciales: el dataset voiced no es un dataset interesante para clasificar voces saludables de patológicas. Entonces, decimos que para realizar correctamente la tarea es necesario grabaciones, no de la voz, sino en las cuerdas vocales pues aquí es donde se observan las patologías.

Por otro lado, se observa que la capacidad de generalización entre datasets no es buena. Esto podría deberse a las diferencias entre distribuciones de los datos, que provienen de distintas 'fuentes' y a la falta de más datos que permitan aprender características de las voces y generalizar correctamente.